



数值分析

计算机科学与技术系
软件所EDA

蔡懿慈

caiyc@tsinghua.edu.cn


第3章 函数逼近与快速傅里叶变换

§ 3.1 函数逼近的基本概念

3.1.1 函数逼近与函数空间

一、函数逼近的提法：

大家对函数逼近已经接触过很多了，比如高等数学的Taylor级数展开，付氏级数展开，是函数逼近的重要方法，第2章学习的插值方法，也是函数逼近的一种方法。Taylor级数研究复杂函数用多项式展开的方法，而付氏级数研究复杂函数用三角函数表达的方法。除此，还有许多其它的函数逼近方法，概括地说：“对函数类A，给定的函数 $f(x)$ ，在相对简单的函数类B中找 $P(x)$ ，使在某种度量意义下，误差函数 $f(x)-P(x)$ 最小。”用图可直观说明如下：



函数类**A**中的 $f(x)$ ，可能是连续函数类中一个比较复杂的函数，希望用较简单函数近似它，也可能是一个表格函数，即知道一系列离散点的函数值，要求配一条连续曲线等，插值逼近以及本章将要讨论的曲线拟合可解决这类函数逼近问题。

简单函数类**B**一般选取：多项式，三角函数，指数函数，有理函数等。

在函数逼近的讨论中，总存在一个问题，如何判断逼近的好与不好。就是说，用一个函数近似另一个函数，总存在误差函数： $f(x) \sim p(x)$ ，需要有一种度量标准去衡量误差的大小。

我们需要对函数这个集合有更深入的认识和了解，这里，我们把函数空间放在一个更广泛、更一般，也更抽象的概念下讨论，就是“线性空间”。

二、线性空间

定义0 S: 非空集合, P: 数域, $x, y \in S$,

而且对加法与数乘具有封闭性:

$$\begin{array}{l} \text{加法} \left\{ \begin{array}{ll} 1、x + y = y + x & \text{可变换} \\ 2、(x + y) + z = x + (y + z) & \text{结合} \\ 3、x + 0 = x & \text{存在零元素} \\ 4、x + (-x) = 0 & \text{存在负元素} \end{array} \right. \\ \\ \text{数乘} \left\{ \begin{array}{l} 5、1x = x \\ 6、(\alpha\beta)x = \alpha(\beta x) \\ 7、\alpha(x + y) = \alpha x + \alpha y \\ 8、(\alpha + \beta)x = \alpha x + \beta x \end{array} \right. \end{array}$$

称S是域P上的线性空间。

定义1 S : 数域 P 上线性空间, $x_1, \cdots, x_n \in S$, $\alpha_1, \cdots, \alpha_n \in P$
有: $\alpha_1 x_1 + \cdots + \alpha_n x_n = 0$

(1) $\alpha_1, \cdots, \alpha_n$ 不全为0, 称 x_1, x_2, \cdots, x_n 线性相关。

(2) 当且仅当 $\alpha_1 = \cdots = \alpha_n = 0$ 成立, 称 x_1, \cdots, x_n 线性无关,
称 x_1, \cdots, x_n 为 S 的一组基。

这时有 $x \in S$ 成立: $x = \alpha_1 x_1 + \cdots + \alpha_n x_n$

即 S 中任一元素可由这组线性无关的基 x_1, \cdots, x_n 线性表示出来。

根据上述定义:

$C[a, b]$: $[a, b]$ 上连续函数全体, 按函数加法与函数复数乘法,
即可构成一线性空间。

$C^p[a, b]$: $[a, b]$ 上 p 阶导数连续函数全体构成的线性空间。

线性空间的上述知识在线性代数中讨论有限维向量空间 R^n 与 C^n 时，已经引出过。但这里已做了推广，一个重要的区别是，一般的线性空间的维数可能是无限维的，大家所了解的Taylor展开和付氏展开一般需要无穷多项去逼近它，正是这个道理。

任一个连续函数，总可以用一定次数的多项式逼近到任意好的程度，下面魏尔斯特拉斯（Weierstrass）定理指出了这种性质：

定理1：设 $f(x) \in C[a,b]$ ，则对任何 $\varepsilon > 0$ ，总存在一个多项式 $p(x)$ ，使 $\|f(x) - p(x)\|_\infty < \varepsilon$ ，在 $[a,b]$ 上一致成立。

3.1.2 范数与赋范线性空间

为了对线性空间的元素大小进行度量，引入如下范数定义：

一、范数定义

定义2 S ：线性空间， $x \in S$ ，若某个实值函数 $N(x)=\|x\|$ 满足条件：

- (1) $\|x\| \geq 0$ 当且仅当 $x=0$ 时， $\|x\|=0$
- (2) $\|\alpha x\|=|\alpha| \|x\|$ ， $\alpha \in R$
- (3) $\|x+y\| \leq \|x\| + \|y\|$

称： $N(x)(=\|\cdot\|)$ 为线性空间 S 上的范数， S 与 $\|\cdot\|$ 一起称赋范线性空间。或者说“定义了范数的线性空间称赋范线性空间。”


常用的连续函数空间使用的范数有三种：

二、三种常用范数

1、 ∞ -范数


$$\|f(x)\|_{\infty} = \max_{x \in [a, b]} |f(x)|$$

几何意义如下：



2、1-范数 $\|f(x)\|_1 = \int_a^b |f(x)| dx$

几何意义如下：




$$\|f(x)\|_1 = S'$$

3、2-范数

$$\|f(x)\|_2 = \left(\int_a^b f^2(x) dx \right)^{1/2}$$

几何意义如下：



$$\|f(x)\|_2 = (S')^{1/2}$$

3.1.4 最佳逼近

$$\|f(x) - p(x)\|_{\infty} \text{ 与 } \|f(x) - p(x)\|_2$$

这里： $f(x)$ ：被逼近函数

$p(x)$ ：逼近函数

$f(x)-p(x)$ ：误差函数

我们先考察以 ∞ -范数作为误差度量标准的某些直观含义：

$$(1) \quad \|f(x) - p(x)\|_{\infty} = \max_{x \in [a, b]} |f(x) - p(x)|$$


这种度量标准下讨论的函数逼近称“均匀逼近”、“一致逼近”。其中：“均匀”、“一致”带有某种直观的几何意义。

从几何上不难理解： $\|f(x) - p(x)\|_{\infty} \leq \varepsilon$ 的含义。

根据范数的定义，上式可写为： $\max_{x \in [a, b]} |f(x) - p(x)| \leq \varepsilon$

即, $-\varepsilon \leq p(x) - f(x) \leq \varepsilon$ 或 $f(x) - \varepsilon \leq p(x) \leq f(x) + \varepsilon$

图示如下:



从图上可以看出, 逼近函数 $p(x)$, 或近似函数能够比较“均匀”、“一致”地在整个区间上逼近被近似函数 $f(x)$ 。


$$(2) \quad \|f(x) - p(x)\|_2 = \left(\int_a^b (f(x) - p(x))^2 \right)^{1/2}$$

$p(x)$ 对 $f(x)$ 在平方范数意义下的逼近，称“平方逼近”或“均方逼近”。平方范数不像 ∞ -范数那样具有直观含义，但它与1-范数具有某种直观相似性，如果近似地认为：

$$\|f(x) - p(x)\|_2 \approx \|f(x) - p(x)\|_1 = \int_a^b |f(x) - p(x)| dx = S \quad \text{即, } S \leq \varepsilon$$

从图上可以看出：

平方范数意义下的平方逼近，一般不再具有“均匀”、“一致”性质，而带有某种“平均”含义，某些区段误差可以很大。



小结：用不同的范数，即不同的度量标准讨论函数最佳逼近问题，则逼近函数对被逼近函数的近似会有不同的表现，与 ∞ -范数对应的一致逼近效果最好。

在本章，我们仅仅讨论最佳平方逼近，即以平方范数作为度量标准的函数逼近问题。它常常涉及函数空间或线性空间内引进的另一种运算性质：**内积**。可以对元素之间的夹角做分析讨论（与向量空间类比）下面简单介绍。

第3章课后练习 (6)

作业：三、2、4 (1) (2)、5、6、12

预习：3.5

3.1.3 内积与内积空间

定义3 X : 数域 K (R 或 C) 上线性空间, $\forall u, v \in X$ $(u, v) \in K$ 并满足:

- 1、 $(u, v) = \overline{(v, u)}$ 共轭可交换性
- 2、 $(\alpha u, v) = \alpha(u, v)$
- 3、 $(u + v, w) = (u, w) + (v, w)$ $\begin{matrix} > \\ \text{线性性} \end{matrix}$
- 4、 $(u, u) \geq 0$, 当且仅当 $u = 0$ 时, $(u, u) = 0$ 非负性

称 (u, v) 为 X 上的**内积**, 定义了内积的线性空间称为**内积空间**。

称 $\overline{(u, v)}$ 为 (u, v) 的共轭, 当 K 为实数域 R 时:

$$(u, v) = (v, u)。$$

强调：对函数空间 $C[a, b]$, $u_1, u_2, v \in [a, b]$ 内积线性性质的表示方式： $(c_1 u_1 + c_2 u_2, v) = c_1 (u_1, v) + c_2 (u_2, v)$

进一步推广为：
$$\left(\sum_{j=0}^n a_j u_j, v\right) = \sum_{j=0}^n a_j (u_j, v)$$

即“线性组合的函数内积=内积的线性组合”。

定理2，柯西—施瓦茨（Cauchy-Schwarz）不等式

X —实内积空间， $\forall u, v \in X$ 有： $| (u, v) |^2 \leq (u, u)(v, v)$

定理证明书上有，请自己看。**注意：**书上证明仅适用于“实”内积空间，对“复”内积空间应做相应的变动，但结论是成立的。

定理3 设 X 为实内积空间, $u_1, u_2, \dots, u_n \in X$, Gram (格拉姆) 矩阵:

$$G = \begin{bmatrix} (u_1, u_1) & (u_2, u_1) \cdots (u_n, u_1) \\ (u_1, u_2) & (u_2, u_2) \cdots (u_n, u_2) \\ \cdots & \cdots \cdots \cdots \\ (u_1, u_n) & (u_2, u_n) \cdots (u_n, u_n) \end{bmatrix}$$

非奇异的充要条件是: u_1, \dots, u_n 线性无关。

下面的证明与书上有些不同, 但大体上是一致的。

证明：下面的证明用到线性代数的一个非常基本的事实。

$$G \text{非奇异} \iff \det(G) \neq 0 \iff \text{齐次方程组}$$

$$\sum_{j=1}^n \alpha_j (u_j, u_k) = 0 \quad (k=1, \dots, n) \text{ 有恒零解}$$

u_1, \dots, u_n 元素是否线性相关，根据定义应有：

$$\alpha_1 u_1 + \alpha_2 u_2 + \dots + \alpha_n u_n = 0 \quad \text{若 } \alpha_1 = \dots = \alpha_n = 0, \text{ 则线性无关}$$

分别用各元素 u_1, \dots, u_n 对上式两端作内积：

$$\begin{cases} \alpha_1 (u_1, u_1) + \alpha_2 (u_2, u_1) + \dots + \alpha_n (u_n, u_1) = 0 \\ \alpha_1 (u_1, u_2) + \alpha_2 (u_2, u_2) + \dots + \alpha_n (u_n, u_2) = 0 \\ \dots \\ \alpha_1 (u_1, u_n) + \alpha_2 (u_2, u_n) + \dots + \alpha_n (u_n, u_n) = 0 \end{cases}$$

由此得到以 $\alpha_1, \dots, \alpha_n$ 为未知数的齐次线性方程组它的系数矩阵正是相应的Gram矩阵, 此时 $\alpha_1 = \alpha_2 = \dots = \alpha_n = 0 \Leftrightarrow G$ 非奇异。

证毕

在内积空间 X , 总可以规定一种依赖于内积运算的范数:

$$\|u\| = \sqrt{(u, u)} = (u, u)^{1/2}$$

根据内积的性质, 包括定理2给出的Cauchy-Schwarz不等式, 可以证明, 上述用内积定义的范数表达式满足范数定义的两条性质。书上有证明, 自己看一下。

书上的证明还是只适用于“实”内积空间, 若要对一般复内积空间, p54倒数第2行的 $2(u, v)$ 应改为 $2|(u, v)|$, 之后再做推导。

例1：给出了 n 维实、复向量空间内积，作为内积空间内积计算的例子，大家看一下。

这里引入了 n 维向量空间中“**加权**”的概念。如实向量空间 $x, y \in R^n$, 给定 $w_i > 0$, $[i=1, \dots, n]$, 称 $\{w_i\}$ 为权系数, 并相应定义加权内积:

$$(x, y) = \sum_{i=1}^n w_i x_i y_i$$

权系数如何确定, 需要根据实际问题而定, 若取 $w_i = 1$, 就是普通不加权的情形。类似地, 可以在函数空间定义权函数概念。

定义4 $\rho(x) \geq 0, \forall x \in [a, b]$ 满足

(1) $\int_a^b x^k \rho(x) dx$ 存在 ($k=0, 1, \dots$)

(2) 对非负连续函数 $g(x)$, 若 $\int_a^b g(x) \rho(x) dx = 0 \Rightarrow g(x) \equiv 0$

称 $\rho(x)$ 为 $[a, b]$ 上的权函数。

定义4中的第2条性质可以表述为另一种等价形式:

$\rho(x) \neq 0 \quad \forall x \in (c, d) \subset [a, b]$ 。这里区间 (c, d) 是 $[a, b]$ 中任一子区间。用语言可表述为: “权函数在 $[a, b]$ 中任一子区间不恒为零”。

例2： 给出了函数空间 $C[a,b]$ 上加权内积的定义。

设 $f(x), g(x) \in C[a,b]$, $\rho(x)$ 是 $[a,b]$ 上给定的权函数, 则可定义内积:

$$(f(x), g(x)) = \int_a^b \rho(x) f(x) g(x) dx \quad (1.15)$$

容易验证它满足内积定义的4条性质, 由此**内积导出**的范数为:

$$\|f(x)\|_2 = (f(x), f(x))^{\frac{1}{2}} = \left[\int_a^b \rho(x) f(x) f(x) dx \right]^{\frac{1}{2}} \quad (1.16)$$

称(1.15)和(1.16)为带权 $\rho(x)$ 的内积和范数, 常用的是 $\rho(x) \equiv 1$ 的情形。

小结：本节介绍了关于线性空间、范数、赋范线性空间、内积以及内积空间一些最基本的知识，它们在“泛函分析”中有系统、全面、深入的理论和研究。下面将以这些基本知识作为基础，对函数逼近的数学方法加以讨论。

§ 3.2 正交多项式

3.2.1 正交函数族与正交多项式

定义5 $f(x), g(x) \in C[a, b]$, $\rho(x)$ 为权函数, 若:

$$(f(x), g(x)) = \int_a^b \rho(x) f(x) g(x) dx = 0$$

则 $f(x)$ 与 $g(x)$ 在 $[a, b]$ 上带权正交。

若函数族 $\varphi_0(x), \dots, \varphi_n(x)$, 满足:

$$(\varphi_j, \varphi_k) = \int_a^b \rho(x) \varphi_j(x) \varphi_k(x) dx = \begin{cases} 0 & j \neq k \\ A_k & j = k \end{cases} \quad (2.2)$$

则称 $\{\varphi_k(x)\}$ 是在 $[a, b]$ 带权 $\rho(x)$ 的正交函数族。若 $A_k \equiv 1$, 称标准正交函数族。

例如：三角函数族： $1, \cos x, \sin x, \cos 2x, \sin 2x, \dots$
是 $[-\pi, \pi]$ 上的正交函数族。

定义6， 设 $\varphi_n(x)$ 是 $[a, b]$ 上首项系数 $a_n \neq 0$ 的 n 次多项式， $\rho(x)$ 是 $[a, b]$ 上的权函数， 如果多项式序列 $\{\varphi_n(x)\}_0^\infty$ 满足关系式 (2.2) ， 则称多项式序列 $\{\varphi_n(x)\}_0^\infty$ 为 $[a, b]$ 上带权 $\rho(x)$ 正交， 称 $\varphi_n(x)$ 为 $[a, b]$ 上带权 $\rho(x)$ 的 n 次多项式。

定义6给出的正交多项式序列的定义与定义5很相似。

P57倒数第9 ~ P58第11行， 正交多项式的性质， 不要求。

3.2.2 Legendre多项式

了解一下即可，但性质4应知道，后面要用到。

3.2.3 切比雪夫多项式

只需要了解一下。

3.2.4 切比雪夫多项式零点插值

不要求。

3.2.5 其它常用正交多项式

只了解，这里很多公式，都不必死记，用时查查即可。

§ 3.3 最佳平方逼近

3.3.1 最佳平方逼近及计算

一、问题提法

在讨论函数的最佳平方逼近时，需要涉及三个基本的相关问题：

(1) 被逼近函数类： $A: C[a,b]$

即 $f(x) \in C[a,b]$: 被逼近函数

(2) 逼近函数类：函数类 B 应比较简单，这表现在

(a) 有限维线性子空间 $\varphi = \text{span}\{\varphi_0(x) \dots \varphi_n(x)\}$ ，由于是有限维线性子空间，函数类 B 中任一元素可以表达为：

$$S(x) = \sum_{j=0}^n \alpha_j \varphi_j(x) \in \varphi \quad \text{其中, } \alpha_0, \dots, \alpha_n \in R \text{ (实数空间)}$$

函数类 B 中任一元素均有由基函数作线性组合的表达式。

(b) 基函数简单

如: $\{1, x, \dots, x^n\}$

$\{1, \cos x, \sin x, \dots, \cos nx, \sin nx\}$

$\{1, e^x, e^{-x}, \dots\}$

{正交多项式族}

{有理函数族}

.....


(3) 误差度量: 2- 范数

函数的最佳平方逼近可以用下式简单表示:

$$\|f(x) - S^*(x)\|_2^2 = \min_{s(x) \in \varphi} \|f - S\|_2^2 = \min_{s(x) \in \varphi} \int_a^b \rho(x) [f(x) - \sum_{j=0}^n a_j \varphi_j(x)]^2 dx$$

$S^*(x)$: 在平方范数度量下, 线性空间 $\varphi = \text{Span}\{\varphi_0, \dots, \varphi_n\}$ 中与被逼近函数 $f(x)$ 的误差最小。

用图可以形象表示函数最佳平方逼近问题:



- ✓ $S^*(x)$ 的构造
- ✓ 存在唯一性
- ✓ 平方误差的计算
- ✓ 基函数的选取

二、 $S^*(x)$ 的构造:

把线性空间 φ 中元素 $s(x)$ 与 $f(x)$ 的距离平方记作:

$$I(a_0, a_1, \dots, a_n) = \int_a^b \rho(x) [f(x) - \sum_{j=0}^n a_j \varphi_j(x)]^2 dx$$

是 a_0, \dots, a_n 的多元函数。因此, 求 $S^*(x)$ 就是求多元函数 $I(a_0, \dots, a_n)$ 关于变量 a_0, \dots, a_n 取极小值的那组变量, 由多元函数取极值的必要条件知, 此时的变量应满足:

$$\frac{\partial I}{\partial a_k} = 0 \quad (k = 0, \dots, n)$$

$$\text{即: } \frac{\partial I}{\partial a_k} = 2 \int_a^b \rho(x) [f(x) - \sum_{j=0}^n a_j \varphi_j(x)] \varphi_k(x) dx = 0 \quad (k = 0, \dots, n)$$

$$\text{改写为: } \int_a^b \rho(x) f(x) \varphi_k(x) dx - \int_a^b \rho(x) \left(\sum_{j=0}^n a_j \varphi_j(x) \right) \varphi_k(x) dx = 0$$

$$\int_a^b \rho(x) f(x) \varphi_x(x) dx - \int_a^b \rho(x) \left(\sum_{j=0}^n a_j \varphi_j(x) \right) \varphi_k(x) dx = 0$$

利用内积记号，上式可以表示为：

$$(f, \varphi_k) - (\varphi_k, \sum_{j=0}^n a_j \varphi_j) = 0 \quad (k = 0, \dots, n)$$

应用内积的线性性质：“线性组合的内积=内积的线性组合”

有：

$$\sum_{j=0}^n a_j (\varphi_k, \varphi_j) = (f, \varphi_k) \quad (k = 0, \dots, n)$$

矩阵形式更好与定理3对照，这是关于 a_0, \dots, a_n 的线性方程组，称为“**法方程**”，其矩阵形式：

$$\begin{bmatrix} (\varphi_0, \varphi_0) & (\varphi_0, \varphi_1) & \cdots & (\varphi_0, \varphi_n) \\ (\varphi_1, \varphi_0) & (\varphi_1, \varphi_1) & \cdots & (\varphi_1, \varphi_n) \\ \cdots & \cdots & \cdots & \cdots \\ (\varphi_n, \varphi_0) & (\varphi_n, \varphi_1) & \cdots & (\varphi_n, \varphi_n) \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \cdots \\ a_n \end{bmatrix} = \begin{bmatrix} (f, \varphi_0) \\ (f, \varphi_1) \\ \cdots \\ (f, \varphi_n) \end{bmatrix}$$

由于 $\varphi_0, \dots, \varphi_n$ 是线性空间 φ 的基函数，线性无关，所构成的 Gram 行列式不为 0，即法方程的系数行列式不为 0，系数矩阵非奇异，方程有唯一解： a_0^*, \dots, a_n^*

$$S^*(x) = a_0^* \varphi_0(x) + \dots + a_n^* \varphi_n(x) \in \varphi$$

特别注意：这里把满足极值必要条件，而非充分要件的 $S^*(x)$ 取作最佳平方逼近函数，未免有些武断。原因是满足极值必要条件的元素不一定能使多元函数取到极值，这种例子在高等数学中已指出过。因此，下面将要证明，满足极值必要条件的 $S^*(x)$ ，确实与 $f(x)$ 具有最小平方距离。

三、证明 $\|f - s^*\|_2 = \min_{S \in \varphi} \|f - s\|_2$

给出详细证明这前，先分析误差函数 $(f - s^*)$ 的一个重要性质，这个性质在证明当中起着关键作用。

1、误差函数 $(f - s^*)$ 的基本性质：

先明确两个符号： $s(x) = \sum_{j=0}^n a_j \varphi_j(x) \in \varphi$ 任一元素

$$s^*(x) = \sum_{j=0}^n a_j^* \varphi_j(x) \in \varphi \quad a_0^*, \dots, a_n^* \text{ 满足 } \frac{\partial I}{\partial a_k} = 0 \quad (k = 0, \dots, n)$$

即， $s^*(x)$ 是 φ 中一个特殊的元素，它的特殊性表现在它的线性组合系数 a_0^*, \dots, a_n^* 满足法方程。

$$\text{即, } \sum_{j=0}^n a_j^* (\varphi_k, \varphi_j) = (f, \varphi_k) \quad (k = 0, \dots, n)$$

$$(\varphi_k, \sum_{j=0}^n a_j^* \varphi_j) = (f, \varphi_k) \quad (k = 0, \dots, n) \Rightarrow (\varphi_k, s^*) = (f, \varphi_k) \quad (k = 0, \dots, n)$$

$$\text{合并: } (f - s^*, \varphi_k) = 0 \quad (k = 0, \dots, n)$$


上式表明, 满足极值必要条件而构造的逼近函数与 $f(x)$ 的误差, 对 φ 空间任一基函数 φ_k 正交, 那么误差函数 $f(x) - s^*(x)$ 也与 φ 中任一元素正交:

$$\Rightarrow (f - s^*, a_k \varphi_k) = 0 \quad a_k \in R, \quad k = 0, \dots, n$$

$$\Rightarrow (f - s^*, \sum_{k=0}^n a_k \varphi_k) = 0$$

$$\Rightarrow (f - s^*, s) = 0 \quad s(x) \in \varphi$$

用图示如下：



强调： 满足极值必要条件而构造的逼近函数最重要、最基本的性质是它与被逼近函数的误差函数垂直于 φ 空间中任一基函数，也就是垂直于 φ 中任一元素，可以表示为：

$$(f - s^*) \perp \varphi_k \quad k = 0, \dots, n$$

$$(f - s^*) \perp S(x) \quad S(x) \in \varphi$$


2、证明：

思路： 证 $\|f - s\|_2^2 \geq \|f - s^*\|_2^2$ 或 $\|f - s\|_2^2 - \|f - s^*\|_2^2 \geq 0$

即证 S^* 与 f 的平方距离的平方不超过 φ 中其它元素对 f 的平方距离平方，即证：

$$D = \int_a^b \rho(x)(f(x) - s(x))^2 dx - \int_a^b \rho(x)(f(x) - s^*(x))^2 dx \geq 0$$

用图可直观理解为：



$$D = \int_a^b \rho(x)(f(x) - s(x))^2 dx - \int_a^b \rho(x)(f(x) - s^*(x))^2 dx$$

$$D = \int_a^b \rho[\cancel{f}^2 - 2fs + s^2 - \cancel{f}^2 + 2fs^* - s^{*2}]dx$$

在余下的项里，希望能配出这样一项：

$$\int_a^b \rho(x)(s(x) - s^*(x))^2 dx = \int_a^b \rho(x)(s^2 - 2ss^* + s^{*2})dx$$

s^2 已有，还缺 $2ss^*$ 及 s^{*2} ，两项，可以加上再减去。

$$\begin{aligned} D &= \int_a^b \rho[-2fs + \underbrace{s^2 + s^{*2} - 2ss^*}_{(s-s^*)^2} - s^{*2} + 2ss^* + 2fs^* - s^{*2}]dx \\ &= \int_a^b \rho(s - s^*)^2 dx + 2 \int_a^b \rho(s^* - s)(f - s^*)dx \end{aligned}$$

注意 D 中的第二项： $\int_a^b \rho(s^* - s)(f - s^*)dx = (s^* - s, f - s^*) = 0$

$$\text{有： } D = \int_a^b \rho(s - s^*)^2 dx \geq 0$$

而且，仅当 $s(x) = s^*(x)$ 时， $D=0$ ，这说明 $s^*(x)$ 是函数空间 φ 中，与 $f(x)$ 有最小平方误差的唯一一个函数。这样，存在唯一性得到证明。

四、 $\|f - s^*\|_2^2$ —最佳平方逼近的误差

$$\text{令： } \delta(x) = f(x) - s^*(x)$$

$$\text{则： } \|\delta(x)\|_2^2 = (f - s^*, f - s^*) = (f - s^*, f) - (f - s^*, s^*)$$

其中，第二项可利用前面导出的最佳平方逼近函数对 $f(x)$ 的误差函数与 φ 空间中任一元素正交，也和自身正交，即为0，因此有：

$$\|\delta(x)\|_2^2 = (f - s^*, f) = \|f\|_2^2 - \sum_{j=0}^n a_j^*(\varphi_j, f)$$

这样，只须计算 $\|f\|_2^2$ ，即可得到误差，比直接计算 $\|f - s^*\|_2^2$ 方便。

五、基函数选择

多项式比较简单，常被取作基函数，比如取 $\varphi = \text{span} \{1, x, \dots, x^n\}$ 但下面的例子说明。若直接选用 $\{1, x, \dots, x^n\}$ 作基函数，计算将出现严重不稳定。

例6, 设 $f(x) = \sqrt{1+x^2}$ 求 $[0, 1]$ 上的 n 次最佳平方逼近多项式。

$\rho(x) \equiv 1$ $f(x) = \sqrt{1+x^2}$ 被逼近函数

若取: $\varphi = \text{span}\{1, x, \dots, x^n\}$ 求: $s^*(x) = \sum_{j=0}^n a_j^* x^j$

其中: a_0^*, \dots, a_n^* 满足如下法方程:

$$\sum_{j=0}^n a_j^* (\varphi_k, \varphi_j) = (\varphi_k, f) \quad k = 0, \dots, n$$

而:
$$(\varphi_k, \varphi_j) = \int_0^1 x^k x^j dx = \frac{1}{k+j+1}$$

$$(\varphi_k, f) = \int_0^1 f(x) x^k dx = d_k$$

记：

$$G_n = \begin{bmatrix} 1 & \frac{1}{2} & \cdots & \frac{1}{n+1} \\ \frac{1}{2} & \frac{1}{3} & \cdots & \frac{1}{n+2} \\ \cdots & & & \\ \frac{1}{n+1} & \frac{1}{n+2} & \cdots & \frac{1}{2n+1} \end{bmatrix}$$

法方程： $G_n a^* = d$

其中： a^* 是 a_j^* 的列向量， d 是右端向量。

G_n 称为Hilbert希尔伯特矩阵，是一个高度病态的矩阵，第五章将详细讨论。这里列出其行列式的大小，加以说明：

$$|G_0| = 1$$

$$|G_3| = 1.7 \times 10^{-7}$$

$$|G_6| = 4.8 \times 10^{-25}$$

$$|G_8| = 9.7 \times 10^{-43}$$

当 n 较大时, $|G_n| \approx 0$, 就是说法方程接近于奇异。因此, 求解 a_j^* 时, 舍入误差将严重影响解的精度。解决办法是:

- ① n 较小时使用
- ② 用双精度数
- ③ 用正交多项式作基

3.3.2 用正交函数族作最佳平方逼近

设: $\{\varphi_0(x), \dots, \varphi_n(x)\}$ 为正交函数族, 即: $(\varphi_k, \varphi_j) = \begin{cases} 0 & j \neq k \\ A_k > 0 & j = k \end{cases}$

则法方程: $\sum_{j=0}^n a_j (\varphi_k, \varphi_j) = (f, \varphi_k) \quad (k = 0, \dots, n)$

由于基函数的正交性, 系数矩阵退化为对角阵:

$$a_k^* = (f, \varphi_k) (\varphi_k, \varphi_k) = (f, \varphi_k) / A_k, \quad (k = 0, \dots, n)$$

因此, 最佳平方逼近多项式可立即给出为: $S^*(x) = \sum_{k=0}^n \frac{(f, \varphi_k)}{(\varphi_k, \varphi_k)} \varphi_k(x)$

避免求解一个变量间相互耦合的法方程, 用正交函数族作最佳平方逼近有以下优点:

(1) 计算稳定, 方便: $a_k^* = \frac{(f, \varphi_k)}{(\varphi_k, \varphi_k)} \quad (k = 0, \dots, n)$

(2) 便于基函数增删, 第 k 个正交基函数的线性组合系数仅仅依赖于第 k 个基函数 $\varphi_k(x)$ 本身。

小结：掌握用正交多项式族做最佳平方逼近的特殊情况和它的优点。了解一下定理8与9即可，定理10可不看。

定理8：是正交式项式族做最佳平方逼近的收敛性定理

定理9：给出平方逼近可在一定条件下达到一致逼近的效果，是非常有意义的结论。希望能了解。

3.3.3 切比雪夫级数

不要求。

第3章课后练习 (7)

作业： 三、14 (2) (3)、15、17、18

预习： 4.1、4.2

§ 3.4 曲线拟合的最小二乘法

3.4.1 最小二乘法及其计算

曲线拟合是讨论连续函数对表格函数的最佳平方逼近。它与用连续函数逼近连续函数的最佳平方逼近，在问题的提法、解决问题的思路、最小二乘逼近函数的构造等方面都十分相似。因此，在下面的介绍中，将突出二者不同的地方，相同的将仅作简要介绍。先介绍几个预备知识。

一、预备知识

1、函数对离散点的加权内积：

定义: $x: x_0, x_1, \dots, x_m$
 $\varphi(x): \varphi(x_0), \varphi(x_1), \dots, \varphi(x_m)$
 $\psi(x): \psi(x_0), \psi(x_1), \dots, \psi(x_m)$
 $w(x): w(x_0), w(x_1), \dots, w(x_m)$

$$\text{称: } (\varphi, \psi) = \sum_{i=0}^m w(x_i) \varphi(x_i) \psi(x_i)$$

为函数 $\varphi(x)$ 与 $\psi(x)$ 对离散点 x_0, \dots, x_m 及权函数 $w(x)$ 的内积,
 $w(x) > 0$ 。

该内积定义同样满足P53定义3关于线性空间内积给出的四条性质, 自己证明一下。

类似地, 利用函数自身内积的非负性可定义平方范数。

2、函数对离散点的平方范数：

$$\|\varphi(x)\|_2 = (\varphi, \varphi)^{1/2} = \left(\sum_{i=0}^n w(x_i) (\varphi^2(x_i)) \right)^{1/2}$$

3、函数族关于离散点的正交：

$$\varphi = \{\varphi_0(x), \dots, \varphi_n(x)\} \quad x_i (i = 0, \dots, m)$$

$$\text{有： } (\varphi_j, \varphi_k) = \sum_{i=0}^m w(x_i) \varphi_j(x_i) \varphi_k(x_i) = \begin{cases} 0 & j \neq k \\ A_k > 0 & j = k \end{cases}$$

4、设 $\varphi_0(x), \dots, \varphi_n(x)$ 及点集 $x_0, \dots, x_m (m > n)$

$$\text{若 } a_0 \varphi_0(x_i) + \dots + a_n \varphi_n(x_i) = 0 \quad (i = 0, \dots, m)$$

当且仅当 $a_0 = \dots = a_n = 0$ 时成立，称 $\varphi_0, \dots, \varphi_n(x)$ 关于点集 x_0, \dots, x_m 线性无关。

定理3’: $\varphi_0(x), \dots, \varphi_n(x)$ 对点集 x_0, \dots, x_m ($m > n$) 线性无关的充要条件是相应的Gram行列式 $\det(G) \neq 0$ 。

定理的证明可仿照定理3，这里不做了。

思考：对区间来说线性无关的一族函数，对点集来说是否也线性无关？

答案是否定的，书P74有个例子说明了这点，大家思考一下。

书上对线性组合函数在点集的零点性质提出一种称为Haar哈尔条件的定义，大家看一下，了解即可。另一方面，《数值分析基础》（关治，陆金甫）的书中有一定理（P128，引理3.1）。

引理3.1： $\varphi_0(x), \dots, \varphi_n(x)$ 如果在 $X = \{x_0, \dots, x_m\} (m \geq n)$ 上满足Haar条件，则 $\varphi_0(x), \dots, \varphi_n(x)$ 在 X 上线性无关。

定理指出：满足Haar条件 \longrightarrow 线性无关。但如何定量判定Haar条件，仍不清楚。所以还是用定理3判断，较为方便与直接。

二、问题提法

首先，明确与最小二乘拟合相关的三个基本问题：

1、被逼近函数类A：表格函数

$$y = f(x) \quad (x_i, y_i) \quad (i = 0, \dots, m)$$

注意：最小二乘逼近的函数不是连续函数，而是表格函数。

2、逼近函数类 B

这与最佳平方逼近采用的简单连续函数大体相同，表现在：

(a) 有限维线性空间： $\varphi = \text{span}\{\varphi_0(x), \dots, \varphi_n(x)\}$

其中， $\varphi_0(x), \dots, \varphi_n(x) \in C[a, b]$

B 中函数有十分简单的结构： $s(x) = \sum_{j=0}^n a_j \varphi_j(x) \in \varphi \quad a_0, \dots, a_n \in R$

(b) 基函数简单

类似地，这里也选择“多项式”，“三角函数”、“指数函数”、“有理函数”等集合。

3、误差度量：关于离散点的平方范数


最小二乘逼近可以简单地表达为：

$$\|f(x) - s^*(x)\|_2 = \min_{s \in \varphi} \|f - s\|_2 = \min_{s \in \varphi} \left(\sum_{i=0}^m [y_i - \sum_{j=0}^n a_j \varphi_j(x_i)]^2 \right)^{1/2}$$

对照最佳平方逼近，从形式上看完全一致，区别仅在范数计算。

找 $S^*(x)$ ：在关于离散点平方范数的度量下，线性空间 $\varphi = \{\varphi_0, \dots, \varphi_n\}$ 中与逼近函数 $f(x)$ 的误差最小。

可用下图形表示：



再强调：最佳平方逼近与最小二乘逼近的区别仅在于被逼近函数类型：

连续函数——最佳平方逼近


表格函数——最小二乘拟合

思考：大家注意到第二章的插值方法，也是讨论为表格函数配曲线的问题，这与最小二乘拟合有什么区别和联系呢？

什么时候应使用最小二乘拟合？

一般来说, 适合使用最小二乘拟合方法配连续曲线的离散点, 大体有以下特点:

(a) 不很准确 (b) 数量大 (c) 有某种分布规律



当数据具有前述几个特点时，若要求像插值那样配一条严格通过每个离散点的曲线，可能会掩盖了这批数据所反映的 x, y 间的依赖关系，这时采用最小二乘拟合会更有意义。

在明确了最小二乘拟合的提法后，具体讨论如何构造最小二乘拟合函数等问题。它与最佳平方逼近函数的构造几乎是平行（一样）的，书上也有简略推导，这里列出标题，大家可依照上节课对最佳平方逼近函数的构造与分析加以充实。

三、 $S^*(x)$ 的构造

把问题转化为求多元函数： $I(a_0, \dots, a_n) = \sum_{i=0}^m w(x_i) [f(x_i) - \sum_{j=0}^n a_j \varphi_j(x_i)]^2$
的极值问题，所有讨论与前面相同。

四、证明 $\|f - s^*\|_2 = \min_{s \in \varphi} \|f - s\|_2$

证明的方法、思路与最佳平方逼近完全相同，关键在于导出最小二乘拟合函数与被逼近函数的误差具有的性质：

误差函数 $f(x) - s^*(x)$ 的重要性质：

$$\left. \begin{array}{l} (f - s^*, \varphi_k) = 0 \\ \text{或 } (f - s^*) \perp \varphi_k \end{array} \right\} k = 0, \dots, n \quad \text{或 } (f - s^*, s) = 0 \quad \forall s \in \varphi$$

推导与证明请自己完成。

五、最小二乘拟合的误差 $\|f - s^*\|_2^2$

$$\|f - s^*\|_2^2 = \|f\|_2^2 - \sum_{j=0}^n a_j^*(\varphi_j, f)$$


六、基函数选择

这里介绍两种常用方法：

1、分析数据规律选基函数

例9：比较简单，自己看。

例10：(x_j, y_j), ($j = 0, 1, 2, 3, 4$) 在表3-1给出，由给定数据在方格纸上绘图：



根据离散点的分布，确定采用指数形式： $y = \gamma e^{bx}$ 描述点的分布比较合适。但应**注意**，上述函数形式应当转换为可由基函数的线性组合表达的形式：

$$s(x) = \sum_{j=0}^n a_j \varphi_j(x)$$

因此，应对函数形式加以处理，两边取对数： $\ln y = \ln \gamma + bx$

作变量代换，令 $\bar{y} = \ln y$, $a = \ln \gamma$ ，则： $\bar{y} = a + bx$ $\varphi = \text{span}\{1, x\}$

确定 a 与 b 即可。

这个例子强调说明以下两点：

(a) 为什么改写拟合函数表达式 $y = \gamma e^{bx}$?

原因是将非线性的函数表达式改写为在适当引入变量代换后，可给出通过基函数线性组合的函数表达式。

(b) 作变量代换后，问题转化为新变量 \bar{y} 与 x 之间的最小二乘拟合问题，必须对原始数据加以改造，就是表3-2第4行给出的数据。

2、正交多项式组作基函数 (3.3.2)

3.4.2 用正交多项式作最小二乘拟合

思考：本章第2节已经介绍5种常用正交多项式族，他们对任意点集是否也正交？举个例子：

P61式（2-9）给出了定义在 $[-1,1]$ ，权函数 $\rho(x)=1$ 的Legendre多项式族的递推公式，并列出0~6次的多项式。

其中： $p_0(x)=1$, $p_1(x)=x$,

$[-1,1]$ 对权函数 $\rho(x)=1$ 正交： $(p_0, p_1) = \int_{-1}^1 1 \cdot x dx = \frac{1}{2} x^2 \Big|_{-1}^1 = 0$

而它们对某一点集 $x_i = -0.5, 0.1, 0.7, 1$ 的内积：

$$(p_0, p_1) = 1 \times (-0.5) + 1 \times 0.1 + 1 \times 0.7 + 1 \times 1 = 1.3 \neq 0$$

结论： $p_0(x)$ 与 $p_1(x)$ 虽然在区间 $[-1,1]$ 正交，但对位于其中的点集 $\{-0.5, 0.1, 0.7, 1\}$ 却不正交。因此，关于区间正交的多项式，对点集不一定正交。


下面给出构造关于点集正交多项式族的公式与证明。

P77的式（4.10）与P77的（4.11）给出了两组公式，可以递推构造关于任意函数及任意点集正交的多项式族，下面证明这样构造的多项式族是两两正交的。

证明： 设点集： x_i ($i = 0, \dots, m$)， 权函数： $w(x) \geq 0$ ， 则有递推式：

$$\begin{cases} p_0(x) = 1 \\ p_1(x) = (x - \alpha_1)p_0(x) \\ p_{k+1}(x) = (x - \alpha_{k+1})p_k - \beta_k p_{k-1}(x) \quad (k = 0, 1, \dots, n-1) \\ \alpha_{k+1} = (xp_k, p_k) / (p_k, p_k) \\ \beta_{k+1} = (p_k, p_k) / (p_{k-1}, p_{k-1}) \end{cases}$$

从这组合式看出，当点集及权函数给出， $p_1(x)$ 中的 α_1 即可求出： $\alpha_1 = (xp_0, p_0) / (p_0, p_0) = (x, 1)$ 。求出 $p_1(x)$ 后，利用递推关系式，计算包含在递推关系中的系数 α_{k+1} ， β_k ，从 $p_k(x)$ 及 $p_{k-1}(x)$ 即可推出 $p_{k+1}(x)$ ，而 α_{k+1} 仅依赖于 p_k ； β_k 依赖于 p_k 与 p_{k-1} ，都是已知的，递推过程可以进行下去：



证明：上述多项式族关于点集 x_i 带权正交

思路：归纳法

设： $\{p_0(x), p_1(x), \dots, p_k(x)\}$ 是按照上面公式构造出来的，要证明它们两两正交，可对 L 作归纳。

$$(1) \quad L = 1 \quad \{P_0, P_1\}$$

$$\text{做内积: } (p_1, p_0) \xrightarrow{\text{代入 } P_1} = ((x - \alpha_1)p_0, p_0)$$

$$\text{打开: } (xp_0, p_0) - \alpha_1(p_0, p_0)$$

$$\text{代入 } \alpha_1: (xp_0, p_0) - \frac{(xp_0, p_0)}{(p_0, p_0)}(p_0, p_0) = 0$$

(2) 设: $L = k$ 时, $\{p_0, \dots, p_k\}$ 正交

即对 k , $(p_k, p_s) = 0 \quad (s = 0, \dots, k-1)$

(3) 证: $\{p_0, \dots, p_k, p_{k+1}\}$ 正交, 即证: $(p_{k+1}, p_s) = 0$

两个简单事实:

$$(a) \quad (xp_t, p_q) = \sum_{i=0}^m w(x_i) x_i p_t(x_i) p_q(x_i) = (p_t, xp_q)$$

(b) $\{p_0, \dots, p_k\}$ 正交

$\Rightarrow \{p_0, \dots, p_k\}$ 可作基函数

\Rightarrow 任一次数 $\leq k$ 的多项式 $Q_k(x)$ 可由这组基函数表示出来:

$$Q_k(x) = \sum_{j=0}^k a_j p_j(x)$$

详细证明如下：

$$\begin{aligned}(p_{k+1}, p_s) &= ((x - \alpha_{k+1})p_k, p_s) - \beta_k(p_{k-1}, p_s) \\ &= (xp_k, p_s) - \alpha_{k+1}(p_k, p_s) - \beta_k(p_{k-1}, p_s)\end{aligned}$$

将s分作三段证明：

$$s = \underbrace{0, \dots, k-2}_a, \underbrace{k-1}_b, \underbrace{k}_c$$

(a) $s \leq k-2$

根据归纳法假设 (2) , $s \leq k-2$ 时, 上式后两项为0。

即: $(p_k, p_s) = (p_{k-1}, p_s) = 0, \quad s \leq k-2$

而第一项: $s+1$ 次 $\because s \leq k-2, \quad s+1 \leq k-1$

$$(xp_k, p_s) = (p_k, xp_s) = (p_k, \sum_{i=0}^{s+1} a_i p_i(x))$$

$$\left. \begin{array}{l} (b) s = k-1 \\ (c) s = k \end{array} \right\} \begin{array}{l} P78, \text{ 有详细证明。} \\ = \sum_{i=0}^{s+1} a_i (p_k, p_i) = 0 \quad (\because i \leq k-1) \end{array}$$

§ 3.5 不要求

§ 3.6 不要求

小结：线性空间、范数、赋范线性空间、内积以及内积空间、线性相关与线性无关、正交函数及正交函数族。

连续函数的最佳平方逼近。

离散函数的最小二乘拟合。